福大智联 • 2026 秋软件工程实践 • 第七组

研英智学 • 考研英语领域智能体助学系统

系 统 设 计 说 明 书

项目名称 研英智学（Kaoyan English Agent）

仓库 H3HN/kaoyan-english-agent

文档版本 V1.1

编写日期 2026 年 11 月 9 日

编写人 黄炜杰（102402126，后端）

修订 黄俊翔（102402125，文档统稿）

适用范围 考研英语一 / 英语二阅读训练子系统

代码基线 main @ 81dc51d（2026-11-09）

目 录

第 1 章 引言 3

1.1 编写目的 3

1.2 项目背景 3

1.3 术语与缩略语 3

1.4 参考资料 4

第 2 章 总体设计 4

2.1 设计原则 4

2.2 系统架构 4

2.3 技术选型 5

2.4 系统形态与模块划分 5

第 3 章 运行环境与部署设计 5

3.1 团队离线管理入口 6

第 4 章 前端设计 6

4.1 页面与路由 6

4.2 状态管理 7

4.3 数据加载策略（当前实现） 7

4.4 后台管理端原型设计（○ 原型扩展） 7

第 5 章 后端设计 8

5.1 分层结构 8

5.2 API 设计（27 个端点） 9

5.3 请求校验与错误约定 10

第 6 章 Agent 子系统设计 10

6.1 工具层（4 个确定性工具） 10

6.2 工作流层（3 类编排） 10

6.3 LLM 边界与降级 11

6.4 运行审计（agent_runs） 11

第 7 章 关键流程设计 11

7.1 阅读训练判分流程 11

7.2 长难句拆解流程 12

7.3 对话意图路由（chat） 12

7.4 题库建库发布流程（团队 CLI） 12

7.5 导入校验与证据定位 12

第 8 章　性能设计 13
8.1 当前实现 13
8.2 已识别的优化方向（未实施） 13
第 9 章　安全设计 13
第 10 章　测试与验证 14
10.1 回归体系 14
10.2 运行时验证范围 14
第 11 章　约束与演进方向 14

说明：本版按团队仓库当前代码修订，替换 V1.0 中来自未合并分支的描述；后台管理端为墨刀原型设计稿，统一标注“○ 原型扩展”，不在当前代码实现范围内。

第 1 章　引言

1.1 编写目的

本文档描述“研英智学 • 考研英语领域智能体助学系统”的系统设计方案，覆盖总体架构、前端、后端、Agent 子系统、关键流程、性能与安全设计，供团队成员开发、联调、评审与答辩使用。配套文档《数据库设计说明书》描述数据层详细设计，《原型设计规约与亮点说明》描述用户端与后台管理端原型。

本版（V1.1）的修订原则：所有接口、行数、表结构、测试数量均以仓库当前主线代码为准；凡尚未合入主线的优化与页面，一律标注为“规划/原型扩展”，不得写成已实现。

1.2 项目背景

面向考研英语一 / 英语二考生的阅读训练工作台，将「长难句拆解 → 真题选项分析 → 生词沉淀 → 间隔复习 → 学习报告」组织为一条可重复执行的学习工作流。调研（56 份问卷，有效样本 41）显示前两大痛点为“长难句读不懂”（综合得分 4.07）与“词汇量不足”（3.88），且 51.22% 的用户最缺“学习计划与监督”。本系统以结构优先、逐项归因、语境沉淀、可核查为差异化定位。

1.3 术语与缩略语

术语	说明
Agent	以确定性工具为核心、LLM 仅负责语言组织的助手子系统
工具（Tool）	后端可审计的确定性函数，事实数据的唯一写入口
工作流（Workflow）	对一次学习请求的工具编排：sentence / options / chat 三类
证据定位	将题目 source_quote 匹配到原文句子并绑定 source_sentence_id 的机制
发布状态机	篇章 draft → reviewed → published（或 publish-practice 直接开放基础练习）
410 契约	已退役的学生端导入 / 管理接口固定返回 HTTP 410 与迁移提示

管理端原型	墨刀设计稿（3 页），标注 ○ 原型扩展，当前代码未实现
单用户本地形态	SQLite 单文件、无账号体系、无多用户隔离的课程项目形态

1.4 参考资料

- 《研英智学 需求文档 v0.2》（docs/需求文档.md）
- 《题库建库与发布操作说明》（docs/题库建库与发布操作说明.md）
- 《福大智联_系统设计说明书》（GB/T 8567-2006 正文，docs/）
- 《福大智联_数据库设计说明书》（docs/）
- 《福大智联_原型设计规约与亮点说明》（docs/）
- 《黄炜杰-原文证据定位说明》《黄炜杰-后端优化说明》（docs/，分支工作记录，仅作参考，不代表当前主线）
- 代码仓库 H3HN/kaoyan-english-agent，当前主线 main @ 81dc51d

第 2 章　总体设计

2.1 设计原则

全系统围绕一条主线设计：「工具负责事实，模型负责表达，数据库负责状态」。具体约束：

- 确定性优先：长难句拆解、选项分析、单词本归档、错题记录等证据敏感路径直接返回工具结果，不经 LLM 改写；
- 可追溯：回答中的工具调用（tool_trace）与真题引用（citations）一律由后端生成，模型无法编造出处；
- 不伪造：缺证据的数据保持待确认状态（如 location_status=pending），不随机兜底；
- 可降级：未配置 LLM Key 时全部核心学习功能可用，仅讲解类能力降级；
- 团队 / 学生边界：题库管理只走服务器本地命令行，学生 API 只读已发布内容。

2.2 系统架构

层次	当前实现
客户端	Chrome / Edge 近两个大版本，桌面优先，窄屏折叠导航
前端	8 个页面 • React 19 + Vite + Tailwind CSS v4 • localStorage 离线兜底 web/（Vite 开发端口 5173）
前端内部	统一 API 客户端 lib/api.ts ｜ 状态 AppStore（单词本 / 练习记录同步）
后端	FastAPI（端口 8000 • 27 个端点） 路由层 app.py ｜ 工作流层 workflows.py ｜ 工具层 tools.py ｜ 校验层 exam_import.py / question_bank.py
数据	SQLite（data/app.db • WAL） 10 张表 ｜ 快照 68 篇 / 340 题 / 1295 句 ｜ 词库 5,064 条 ｜ 审计与运行日志

模型	LLM（DeepSeek，可选）：仅开放讲解 / 解析预生成 / 句子拆解生成；未配置 Key 自动降级确定性答案
团队入口	服务器本地命令行：question_bank.py 建库/审核/发布 | setup_team.py 首次安装 | export_demo.py 快照导出
管理端	墨刀原型 3 页（○ 原型扩展，不在代码中）：真题导入工作台 / 词库与熟词僻义管理 / 运行监控看板

图 2-1　系统总体架构（分层）

边界说明：管理端目前只有原型，没有可运行的界面与后台接口；真实管理入口是第 3.1 节的团队命令行。

2.3 技术选型

层	技术	选择理由
前端	React 19 + Vite + Tailwind CSS v4 + TypeScript	组件化工作台界面；Vite 提供开发代理与快速构建；类型约束降低接口联调错误
后端	Python 3.11/3.12 • FastAPI • Pydantic	声明式参数校验与自动 API 文档（/docs）；同步路由模型与 SQLite 配合简单
存储	SQLite（WAL 模式，外键开启）	单机课程项目零运维；WAL 支撑读写并发；外键保证题库参照完整性
LLM	DeepSeek（OpenAI 兼容接口，server/.env 配置）	低成本中文讲解质量好；Key 只存服务端，未配置自动降级
测试	unittest + FastAPI TestClient + vite build（tsc）	零外部依赖的回归体系；内存 SQLite + 模型桩隔离真实数据

2.4 系统形态与模块划分

模块	形态 / 技术	职责与定位
web/	React SPA	当前主入口。8 页面学习工作台：首页、长难句拆解、阅读真题训练、AI 对话、我的单词本、资料库、学习报告、领域知识库
server/	FastAPI	领域数据、4 个确定性工具、3 类工作流、学习状态持久化、题库 CLI 脚本集
kaoyan_agent/	Streamlit	早期 MVP，保留作参考，不在当前改造范围
管理端原型	墨刀	3 页设计稿，○ 原型扩展；当前无代码实现，落地排入后续迭代

题库规模（快照实测）：英语一 2018 / 2019 / 2021－2026，英语二 2018－2026；每卷阅读 Part A 四篇 20 题（原卷题号 21－40）；另有 2 篇 3 题种子示例。快照携带 6 份已缓存句子拆解。

第 3 章　运行环境与部署设计

项	设计
客户端环境	Chrome / Edge 近两个大版本；桌面优先，窄屏折叠为抽屉导航（响应式）

服务端运行时	Python 3.11 / 3.12；Node.js 20+ / 24+；Windows PowerShell 下使用 npm.cmd 与虚拟环境解释器完整路径
进程拓扑	前后端两个独立进程：uvicorn 监听 127.0.0.1:8000，Vite dev 5173 通过 proxy 转发 /api；生产可用 VITE_API_BASE 指向独立后端
首次初始化	python scripts/setup_team.py：全新库恢复快照 → 校验全库（68 篇 / 340 题 / 完整性 / 外键）→ publish-practice 开放基础练习 → 输出审计；已有数据库时拒绝覆盖，保护学习记录
数据文件	server/data/app.db（运行时创建）；共享快照 demo_snapshot.json（仅 auto_/bank_/custom_ 内容，不含个人记录、密钥、原始 PDF）
密钥管理	server/.env 配 LLM_API_KEY / LLM_BASE_URL / LLM_MODEL；.gitignore 忽略，不进入 VITE_* 前端变量

3.1 团队离线管理入口

命令	作用
scripts/question_bank.py	题库全生命周期：template / validate / import / analyze / review / publish / publish-practice / withdraw / export / update / history
scripts/setup_team.py / load_demo.py / export_demo.py	首次安装 / 快照恢复（重置为草稿）/ 快照导出
scripts/auto_import.py	旧 HTTP 导入占位提示（已退役）

管理入口是服务器本地命令行而非公开 HTTP 接口：需要文件系统访问权限，--actor 为审计署名而非登录认证。旧 POST /api/exams/import、POST /api/exams/auto-import、GET /api/agent/runs 固定返回 410 并提示迁移。

V1.0 中列出的 scripts/locate_evidence.py 属于未合入主线的分支工作，当前仓库不存在该脚本，本版已删除。

第 4 章　前端设计

4.1 页面与路由

页面	核心组件	主要能力	主要接口
首页	DashboardPage	四张可点击指标卡、到期单词横幅、功能入口、今日任务、最近练习	/api/meta、/api/state
长难句拆解	SentencePage	篇章/句子选择、结构着色、五步拆解（找主干→剥离从句→划分修饰→逐层翻译→标注语法点）、结构树、大纲词核验、真题溯源、一键加词	/api/passages、/api/passages/{id}/sentences、/api/sentences/{id}/breakdown、/api/workflow/sentence
阅读真题训练	OptionsPage	年/卷/Text 三级筛选、左文右题、提交判分、A-D 逐项陷阱分析、原文高亮定位、练习落库	/api/questions/full、/api/workflow/options、/api/records
AI 对话	ChatPage	上下文篇章选择、6 个预设问题、自由提问、分节回答、工具链与引用展示	/api/workflow/chat

我的单词本	WordbookPage	指标卡、全部/今日复习/添加三页签、复习交互（记住/没记住）、间隔推进	/api/wordbook CRUD、/api/wordbook/review
资料库	LibraryPage	大纲词汇检索（防抖/等级/排序/跳页）、真题篇章卡片、一键加词、去做题深链	/api/vocab、/api/vocab/search、/api/passages
学习报告	ReportPage	总览指标、五类题型正确率、薄弱环节（<70%）、建议、近 7 天柱状图	AppStore 本地计算（records）；/api/report 已提供聚合接口但页面当前未接入
领域知识库	KnowledgePage	熟词僻义示例、题型方法论、8 类陷阱、两套方法、关键词过滤	/api/knowledge

4.2 状态管理

全局状态集中在 AppStore（React Context）：单词本 words 与练习记录 records 以后端为持久化来源，挂载时经 /api/state 同步；后端不可用时回落 localStorage（键 kaoyan-studio-v1）仅作离线兜底，界面同时标注「本地模式」。所有 /api 请求统一收口到 web/src/lib/api.ts，集中处理结构化错误（detail.message + detail.issues 拼接）。

4.3 数据加载策略（当前实现）

阅读训练页面当前采用一次性全量加载：调用 GET /api/questions/full 获取 340 题完整数据（题目内嵌所属篇章全文），前端在内存中按 年 / 卷 / Text 分组筛选。web/src/lib/api.ts 的 getQuestionsFull() 不接受筛选参数。

已识别的优化方向（尚未实施）：为接口增加 include_passage 参数与 year/exam_type/text_number 筛选，目录段只取题目元数据、选中篇后再拉取带原文的详情，形成“两段式加载”。该优化属于后续迭代，本版文档不将其视为已实现能力。

4.4 后台管理端原型设计（○ 原型扩展）

4.4.1 定位与边界

- 形态：本地单机后台。只服务本地演示库与团队离线运维，不做联网部署、不做账号体系、不做多用户隔离。
- 范围：管理“内容”而非“用户与数据库表”——题库导入审核发布、词库与熟词僻义、Agent 运行监控。
- 实现状态：3 页均为墨刀设计稿，标注 ○ 原型扩展；当前代码没有后台路由、没有后台登录、没有写接口。
- 演进：多用户、角色权限（RBAC）与联网部署列入第 4–6 周迭代，本期只在页面备注中说明，不画进画面。

4.4.2 三页原型清单

页面	核心区域	现有代码支撑	状态

真题试卷与切片结构化导入后台	左侧上传与解析、中间篇章/句子切片预览、右侧题目与答案校验；底部审核、发布、撤回操作条	scripts/question_bank.py 状态机；exam_import.py 校验与切句；bank_events 审计	○ 原型扩展
领域知识库与熟词僻义管理后台	词条表格（筛选/分页）、词条编辑抽屉、熟词僻义对照、陷阱规则维护、Prompt 版本区	GET /api/knowledge；syllabus_vocabulary / trap_rules 表；data/rare_meanings.json（27 条）	◐ 只读接口已有，写接口与 Prompt 版本表缺失
Agent 运行监控与学情数据看板后台	运行指标卡、工作流调用趋势、工具链明细、异常与降级、学情分布	agent_runs 表；practice_records；GET /api/report 聚合	◐ 数据表已有，管理端查询接口缺失

表 4-1　后台管理端 3 页原型与代码支撑对照

4.4.3 原型到实现的差距

缺口	现状	落地所需
后台入口与身份	无 admin 路由；全站无登录与鉴权	独立路由或独立应用 + 本地管理员口令（本期不做 RBAC）
题库写操作	POST /api/exams/import 与 auto-import 均返回 410；ExamImportForm 组件存在但未挂载	草稿表与草稿读写、解析预览、审核提交接口；先解除 410 契约
词库写操作	仅 GET /api/knowledge、GET /api/vocab 只读	词条新增/修改/停用接口 + 操作审计
Prompt 版本	server/prompts.py 为常量	prompt_templates 表 + 版本发布与回滚
运行监控	agent_runs 只记录 sentence / options 两类工作流；GET /api/agent/runs 返回 410	chat 工作流补日志；管理端只读查询接口；Token 用量字段

答辩口径：作业要求的是“后台管理原型”，本系统按本地单机形态交付 3 页设计稿；管理端代码列入后续迭代，不与本次原型交付混同。

当前真实可用的管理入口仍是团队命令行（3.1 节）：建库、校验、审核、发布、撤回全部通过 scripts/question_bank.py 完成，全流程写入 bank_events 审计。管理端原型的目标是把这条 CLI 链路可视化，而不是另起一套业务逻辑。

第 5 章　后端设计

5.1 分层结构

文件	行数	职责
app.py	761	路由层：27 个端点、请求模型、依赖注入（每请求独立 SQLite 连接）、410 契约
workflows.py	682	工作流层：句子 / 选项 / 对话编排、chat 意图路由、agent_runs 审计写入（当前为 sentence / options 两处）

tools.py	706	工具层：4 个确定性工具 + 领域查询（词库检索、报告聚合、状态同步）
exam_import.py	186	校验层（纯函数）：题号/答案/结构校验、文本规范化、分段切句、字符偏移、引文定位
question_bank.py	335	题库领域：导入/审核/发布/撤回/更正/解析生成状态机与 bank_events 审计
db.py	194	Schema 定义（10 表）、连接（WAL + 外键）、增量迁移
llm.py	636	LLM 客户端：拆解生成、解析批量生成、chat 润色、健康状态
seed.py	451	种子数据：词库导入、2 篇示例、8 条陷阱规则、演示学习状态

行数为 2026-11-09 当前主线实测。V1.0 中的 537 / 710 / 194 行对应未合并分支，本版已按主线更正。

5.2 API 设计（27 个端点）

端点统计口径：GET / 根路径 1 个 + 学习侧 23 个 + 团队侧 3 个 = 27 个。

5.2.1 学习侧（学生可用，24 个，含根路径）

方法	路径	说明
GET	/	服务信息入口
GET	/api/health	健康检查 + 规模统计 + llm_configured
GET	/api/meta	首页 / 知识库指标
GET	/api/state	单词本与练习记录同步
GET	/api/sentences	已发布句子列表
GET	/api/passages	已发布篇章列表（内存按 year/exam/text 分组去重）
GET	/api/passages/{id}/sentences	指定篇章句子（词数、是否长难句）
GET	/api/sentences/{id}/breakdown	句子五步拆解（缓存优先，未配置 Key 时新句子降级）
GET	/api/questions	题目简要列表
GET	/api/questions/full	完整题目：一次性返回全部题目（含内嵌原文），前端内存分组
GET	/api/knowledge	陷阱规则与熟词僻义
POST	/api/workflow/sentence	句子拆解工作流
POST	/api/workflow/options	选项分析工作流（含判分与记录）
POST	/api/workflow/chat	对话工作流（意图路由 + 可选 LLM 润色）
GET	/api/wordbook	读取单词本
POST	/api/wordbook	新增单词（次日首复习）
DELETE	/api/wordbook/{spelling}	删除单词
POST	/api/wordbook/review	提交复习结果（间隔与掌握度更新）
POST	/api/records	写入练习记录（服务端按库内答案判分）
GET	/api/report	学习报告聚合（含 trap_distribution）
GET	/api/vocab	词库分页检索（LIMIT/OFFSET，等级/排序）
GET	/api/vocab/search	词库快速搜索
POST	/api/tools/check-vocab	大纲词核查工具直调
GET	/api/tools/search-exams	真题切片检索工具直调

5.2.2 团队侧（固定 410，3 个）

方法	路径	说明
POST	/api/exams/import	已停用，返回 410 + 迁移提示（学生导入入口关闭）
POST	/api/exams/auto-import	已停用，返回 410（原自动 PDF 导入）
GET	/api/agent/runs	已停用，返回 410（运行日志离线查 SQLite）

5.3 请求校验与错误约定

- 入参校验：Pydantic 模型统一约束（长度、正则、范围）；查询参数用 FastAPI Query（ge/le/pattern），如 year 2000–2100、text_number 1–4，越界返回 422。
- 结构化错误：校验失败返回 {detail: {code, message, issues[]}}；前端 api.ts 统一拼接展示。
- 判分主权：/api/records 与选项工作流均按库内答案判分，不信任客户端声称的 correct_answer。
- 发布隔离：学生读取路径全部带 publication_status='published' 联表过滤，未发布 ID 直接请求返回 404，不能绕过。
- 幂等与降级：后端不可用时前端不白屏（显式错误 / 本地模式提示）；未配置 Key 时证据敏感请求返回确定性结果。

第 6 章　Agent 子系统设计

6.1 工具层（4 个确定性工具）

工具	输入 → 输出	事实边界
check_syllabus_vocab	句文本/词表 → 词条命中、等级、考频、熟词僻义	词库数据只读；词条属性不被模型改写
search_past_exams	query / grammar / limit → 真题切片 + 出处标签	引用必须来自句子表，出处强制标注
add_to_vocab_book	单词、释义、出处、语境 → 归档结果	带原句语境入库；chat 中的加词确认保持确定性
record_trap_mistake（实现函数 tools.record_option_attempt）	题目、作答、答案 → 练习记录 + 陷阱类型	判分用库内答案；记录落 practice_records

6.2 工作流层（3 类编排）

工作流	编排流程
sentence（句子）	读句子 → check_syllabus_vocab 核验 → search_past_exams 检索（当前句强制置顶引用，不被同标签挤出）→ 返回词表 + 引用 + 工具链；拆解缓存优先
options（选项）	读题目 → 定位来源句（exact_quote 才绑定）→ search_past_exams 引用 → record_trap_mistake 记录 → 返回四选项分析 + 步骤 + 出处 + 工具链

chat（对话）	意图路由（8 个分支）→ 证据敏感问题转发对应工作流拿确定性结果 → 仅开放讲解走 LLM 润色 → 统一返回分节回答 + 工具链 + 引用

图 6-1　Agent 工具-模型边界与审计链路（文字示意）

链路：用户请求 → chat / sentence / options → 确定性工具（事实 • 状态 • 引用）→ LLM（受限，仅语言组织，可失败）→ 分节回答 + tool_trace + citations → agent_runs 审计。tool_trace 与 citations 永不由模型生成。

6.3 LLM 边界与降级

路径	是否调用 LLM	说明
句子拆解（已缓存）	否	直接读 sentence_breakdowns 缓存
句子拆解（未缓存）	是（生成后缓存）	首次约 5–10 秒，有加载提示；失败不落伪造缓存
选项分析 / 判分 / 归档	否	证据敏感，锁定确定性工具结果
chat 意图路由与证据类回答	否	关键词路由 + 转发工作流
chat 开放讲解（复习计划等）	是（仅润色文字）	失败或未配置 Key → 返回确定性 base 结果
chat 中含加词确认	否	状态变更确认永远确定性
解析预生成（团队 CLI analyze）	是	锁外调用、五题全部有效才落库，费用由团队控制

6.4 运行审计（agent_runs）

当前实现：sentence 与 options 两类工作流在 workflows.py 的 _log_run 中写入 agent_runs，字段为 workflow、input_json、output_json、tool_trace_json、created_at。

尚未实现（与 V1.0 的差异）：chat 工作流没有写 agent_runs，也没有 direct / chat 来源标记；因此“一次对话产生两条审计记录”的描述属于未合并分支，本版不采用。该缺口已列入后续迭代。

第 7 章　关键流程设计

7.1 阅读训练判分流程

前端 OptionsPage（选中篇 → 全量数据中筛选）→ POST /api/workflow/options {question_id, user_answer}

- get_question（published 过滤；不存在 → 404）
- 定位句：source_sentence_id 存在且 location_status == exact_quote 才展示
- search_past_exams（来源句前 70 字符为 query）
- record_option_attempt → practice_records 落库（is_correct 按库内答案）
- 返回 {question, source_sentence, citations, is_correct, selected_trap, tool_trace}
- 前端并行 POST /api/records（基础练习题：只保存作答，不生成缺失解析）

7.2 长难句拆解流程

GET /api/sentences/{id}/breakdown：命中 sentence_breakdowns 缓存则直接返回（标注 llmUsed）；未缓存且已配置 Key 时由 LLM 生成五步结构并写缓存后返回。

POST /api/workflow/sentence：check_syllabus_vocab（等级 / 考频 / 熟词僻义，top12 排序）→ search_past_exams + 当前句强制置顶引用 → 返回词表与引用；一键加词走 POST /api/wordbook，自动带出处与原句语境。

7.3 对话意图路由（chat）

workflows.py 的确定性路由按关键词分 8 个分支，全程无模型参与：

- ① 写入单词本：展示 Agent 对软件状态的直接操作（add_to_vocab_book）；
- ② 长难句：从句 / 长难句 / 拆解 / 句子 → 转发句子工作流，取最长句；
- ③ 选项陷阱：转发选项工作流，取第一题；
- ④ 熟词僻义：get_rare_words 检索；
- ⑤ 核心词提炼：上下文驱动，提取核心词并给例句；
- ⑥ 复习计划：get_report 聚合 → 输出到期词 / 薄弱题型 / 建议；
- ⑦ 段落主旨：上下文篇章首尾句确定性归纳；
- ⑧ 默认：能力与数据状态（兜底）。

每类均带 llm_policy；仅开放讲解类进入 _chat_pipeline 的 polish_chat 润色。

7.4 题库建库发布流程（团队 CLI）

整理 JSON（原卷题号 21–40、逐字引文）→ validate（格式 / 题号 / 选项 / 答案校验）→ import（每篇独立事务；部分失败逐项报告）→ draft → [可选] analyze 模型预生成解析（锁外调用，五题全部有效才落库）→ review --confirm-checked（人工逐题核对；非唯一引文必须 evidence_note 说明跨句 / 全文证据，拒绝伪绑定）→ publish（完整教学解析发布）或 publish-practice（答案来源齐全即可开放基础练习）→ 学生 API 只读 published；错误内容 withdraw 撤回 → 修正 → 重走审核。全流程写 bank_events 审计（快照 + 操作人 + 版本）。

7.5 导入校验与证据定位

导入阶段由 exam_import.locate_quote 对每道题的 source_quote 做匹配，返回四种状态：

状态	语义	绑定规则
exact_quote	唯一匹配且落在单个可靠句内	绑定 source_sentence_id，学生端展示定位与来源句
ambiguous	引文在文中多处出现	不绑定，需人工补充证据说明
multi_sentence	引文跨多句	不绑定，需 evidence_note 说明跨句证据
pending	引文缺失 / 过短 / 无法匹配	不绑定，审核时强制要求 evidence_note

question_bank.py 在 review 环节检查：location_status 非 exact_quote 且 evidence_note 为空时直接拦截，提示补写跨句 / 全文证据。

V1.0 描述的“批量重算脚本 locate_evidence.py、141/340 绑定、审计动作 evidence_located”均来自未合并分支，当前仓库不存在该脚本与审计动作，本版改按导入期定位描述。

第 8 章　性能设计

8.1 当前实现

- 题目读取：GET /api/questions/full 一次性返回全部题目（含内嵌原文），前端在内存中分组；尚未做批量查询重构与响应瘦身。
- 词库检索：LIMIT / OFFSET 分页，配合等级与排序条件（exam_frequency DESC, word ASC），5,064 条量级实测毫秒级。
- 句子拆解缓存：重复访问零模型调用。
- SQLite WAL 支撑读写并发；写事务（BEGIN IMMEDIATE）内不等待模型调用。

8.2 已识别的优化方向（未实施）

方向	目标	状态
questions/full 批量查询	用题目批查 + 句子 IN 批查 + 篇章 IN 批查替代逐题组装，消除 N+1	规划
响应瘦身 + 两段式加载	新增 include_passage=false，目录段不返回原文；选中篇再拉详情	规划
审计补齐	chat 工作流写 agent_runs，并区分 direct / chat 来源	规划
索引下沉	exam_passages(year, exam_type, text_number) 唯一索引；practice_records(question_id) 索引	规划

本版不引用任何未在当前主线复现的性能数字（如 59ms / 950KB / 28KB），避免文档与代码不一致。

第 9 章　安全设计

项	设计
密钥管理	LLM Key 只存服务端 server/.env（gitignore）；不进入前端构建产物
发布边界	学生 API 只读 published；未发布 ID 直连 404；无 HTTP 管理入口（团队 CLI 需服务器文件权限）
判分主权	服务端按库内答案判分，不信任客户端
数据不伪造	缺证据保持 pending / unverified；解析缺失不生成编造陷阱分析
退役接口	410 契约；/api/exams/auto-import 的实现体内仍保留 _download_pdf_text（具备 URL 抓取能力），该路由被 410 锁死；解除 410 前必须先移除该函数
审计	bank_events（题库全操作快照）+ agent_runs（sentence / options 工作流运行）
已知限制	当前为单用户本地应用：无账号 / 多用户隔离；CORS 允许 *（本地开发形态，公网部署前需收紧并加鉴权）

V1.0 写“含 SSRF 风险的 PDF 下载死代码已删除”，与当前主线不符：该函数仍存在于 app.py，只是被 410 契约挡住，本版已如实更正。

第 10 章　测试与验证

10.1 回归体系

测试文件	数量	覆盖
test_db_migrations.py	7	新 schema、旧库迁移幂等、快照往返、迁移先于 seed
test_exam_import.py	26	答案序列、乱序/缺题拒绝、切句偏移（含 Unicode）、locate_quote 四态
test_question_bank.py	14	题库生命周期：草稿隔离、审核拦截、发布可见、版本冲突、部分成功、事务回滚、判分主权、410 契约
合计	47	后端全量回归（内存 SQLite + 模型桩，不碰真实库、不请求外部模型）

执行命令：cd server && python -m unittest discover -s tests -p "test_*.py" -v；前端 npm run build（tsc 类型检查 + vite 生产构建）。

V1.0 的“58 项回归、5 个测试文件”包含未合并分支新增的 test_evidence_locator.py（9 项）与 test_api_optimizations.py（12 项），当前仓库不存在，本版按 47 项如实修订。

10.2 运行时验证范围

- API 兼容性：27 个端点的路径与方法与代码一致；参数越界返回 422；三处退役接口返回 410。
- 数据完整性：PRAGMA integrity_check 与外键检查通过；快照恢复后 68 篇 / 340 题 / 1295 句可校验。
- 审计链路：sentence 与 options 工作流各产生一条 agent_runs 记录；chat 审计缺口见 6.4。
- 前端：8 个路由可构建、可加载；读训练页全量加载路径可用。

第 11 章　约束与演进方向

项	现状与演进
后台管理端	当前仅 3 页墨刀原型（○ 原型扩展），真实入口为团队 CLI；演进：第 4 周 M4 后台最小可用（导入工作台只读 + 运行监控）
多用户	无账号体系；公网 SaaS 前需增加用户表、鉴权与数据隔离
唯一约束	exam_passages 尚无 (year, exam_type, text_number) 数据库级 UNIQUE，查重靠应用层；演进：存量去重后建唯一索引
报告口径	前端报告页本地计算与 /api/report 并存；演进：前端统一切换到后端聚合
复习算法	简化 SM-2（间隔 1/2/4/7/15/30 封顶；easiness 字段未启用）；演进：完整 SM-2
移动端	Web 响应式；原生 APP / 小程序为调研提出的后续项
学习计划	静态今日任务 + 到期提示；周计划 / 提醒 / 监督机制为明确缺口（调研第一需求 51.22%）
OCR / PDF 定位	扫描件需先行 OCR；字符偏移对应入库文本，非 PDF 页面坐标